

ГУАП

КАФЕДРА № 41

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

к.т.н., доцент

должность, уч. степень, звание

подпись, дата

Т. А. Волкова

инициалы, фамилия

ОТЧЕТ О ПРАКТИЧЕСКОЙ РАБОТЕ №1

СТАТИСТИЧЕСКОЕ ИССЛЕДОВАНИЕ ДАННЫХ

по курсу: «СТАТИСТИЧЕСКАЯ ОБРАБОТКА ИНФОРМАЦИИ»

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. №

4414

подпись, дата

С. В. Мельник

инициалы, фамилия

Санкт-Петербург 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Основная часть	4
1.1 Поиск данных	4
1.2 Выборочные оценки числовых характеристик данных	7
1.3 Оценка плотности распределения	14
1.4 Интервальные оценки числовых характеристик данных	21
1.5 Выводы	24
2 Дополнительная часть	26
2.1 Оценка дополнительных данных	26
2.2 Построение Boxplot	28
2.3 Расчёт дополнительных числовых показателей	29
2.4 Выводы	31
ЗАКЛЮЧЕНИЕ	34
ПРИЛОЖЕНИЕ	35

ВВЕДЕНИЕ

Статистический анализ данных является фундаментальным инструментом для выявления закономерностей, оценки характеристик и принятия обоснованных решений в различных сферах деятельности. В условиях роста объёмов информации и усложнения структур данных особенно важно владеть методами статистической обработки, позволяющими не только описывать выборки, но и проверять гипотезы о распределении, строить интервальные оценки и выявлять аномальные наблюдения.

Цель работы – провести комплексное статистическое исследование данных, включая расчёт выборочных характеристик, проверку гипотезы о нормальности распределения и построение доверительных интервалов.

1 Основная часть

1.1 Поиск данных

Для статистического исследования в рамках практической работы были взяты данные о туристах, посетивших страны Азии и Тихого океана.

Источник: UN Tourism

Раздел: UN Tourism Data Dashboard/Compare Indicators/Countries
(Ссылка: <https://www.untourism.int/tourism-data/un-tourism-tourism-dashboard>)

Показатель: International Tourist Arrivals (million) 2023
(Международные прибытия туристов в млн человек за 2023 год)

Данные: описывают количество иностранных граждан, прибывших в каждую страну региона «Asia and Pacific» (Азия и Тихий океан) в 2023 году. Из представленных в таблице были отобраны данные о посещениях именно иностранными туристами (серия TF – Total Foreign – все иностранные туристы).

Единицы измерения: миллионы человек (млн чел.)

Объём выборки: $n = 34$

Данные получены из интерактивного дашборда Microsoft Power BI, интегрированного в сайт UN Tourism.

Информация о турпотоке представлена в таблице 1.

Таблица 1 – Исследуемые данные

Country	Int. Tourist Arrivals (million)	Series
Thailand	28,2	TF
Malaysia	20,1	TF
India	18,9	TF
Hong Kong (China)	17,2	TF
Macao (China)	14,2	TF
Indonesia	11,4	TF
Singapore	10,8	TF
Cambodia	5,5	TF
Philippines	5,5	TF

Laos	3,1	TF
New Zealand	2,8	TF
Pakistan	2,2	TF
Maldives	1,9	TF
Sri Lanka	1,5	TF
Myanmar	1,3	TF
Nepal	1	TF
Fiji	0,93	TF
Guam	0,66	TF
Mongolia	0,59	TF
French Polynesia	0,26	TF
Samoa	0,17	TF
Cook Islands	0,14	TF
Brunei	0,13	TF
New Caledonia	0,13	TF
Papua New Guinea	0,11	TF
Vanuatu	0,08	TF
Timor-Leste	0,08	TF
American Samoa	0,06	TF
Tonga	0,06	TF
Palau	0,04	TF
Solomon Islands	0,03	TF
Kiribati	0,01	TF
Marshall Islands	0,01	TF
Micronesia FSM	0	TF

Для наглядного представления данных на их основе с помощью языка Python была построена гистограмма (рис. 1). Программа выполнена в Google Colab.




Рисунок 1 – Гистограмма данных о туристах

Всего стран: 34

Общее количество туристов за 2023 год: 149,1 млн чел.

Максимальное количество туристов в стране: 28,2 млн чел.

Минимальное количество туристов в стране: 0,0 млн чел.

Распределение стран по диапазонам:

- Больше 20 млн чел.: 2 страны
- 10-20 млн чел.: 5 стран
- 0-10 млн чел.: 27 стран

Из гистограммы видно, что страной-лидером по турпотоку с большим отрывом является Таиланд (28,2 млн чел.), за ней идут Малайзия (20,1 млн чел.), Индия (18,9 млн чел.) и Гонконг (17,2 млн чел.). При этом большинство других стран региона имеют гораздо меньшие показатели количества туристов, и это говорит, что основной поток (больше половины) идёт в страны-лидеры.

1.2 Выборочные оценки числовых характеристик данных

Для выполнения выборочной оценки необходимо вычислить следующие оценки:

Выборочное среднее:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad (1)$$

Где:

$\bar{x}$ – выборочное среднее;

n – количество элементов выборки;

x_i – элемент выборки.

Представляет собой среднее арифметическое всех элементов выборки.

Выборочный начальный момент порядка l :

$$a_l = \frac{1}{n} \sum_{i=1}^n x_i^l, \quad (2)$$

Где:

a_l – выборочный начальный момент порядка l ;

n – количество элементов выборки;

x_i^l – элемент выборки в степени l .

Представляет собой среднее значение l -ой степени элементов выборки и характеризует распределение данных относительно начала координат.

Выборочный центральный момент порядка l :

$$m_l = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^l, \quad (3)$$

Где:

m_l – выборочный центральный момент порядка l ;

n – количество элементов выборки;

x_i – элемент выборки;

$\bar{x}$ – выборочное среднее.

Представляет собой значение l -ой степени отклонений элементов выборки от среднего значения и характеризует форму распределения относительно его центра.

Смещённая выборочная дисперсия:

$$s^2 = m_2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, \quad (4)$$

Где:

s^2 – смещённая выборочная дисперсия;

m_2 – выборочный центральный момент 2-го порядка;

n – количество элементов выборки;

x_i – элемент выборки;

$\bar{x}$ – выборочное среднее.

Представляет собой средний квадрат отклонений значений от их среднего и показывает, насколько сильно разбросаны данные вокруг среднего значения.

Выборочное среднее квадратическое отклонение:

$$s = \sqrt{s^2}, \quad (5)$$

Где:

s – выборочное среднее квадратическое отклонение;

s^2 – смещённая выборочная дисперсия.

Представляет собой типичное отклонение отдельных значений от среднего.

Вычисления выборочных оценок проводились с использованием Python.

По формуле (1) рассчитаем выборочное среднее:

$$\bar{x} = 4,385 \text{ млн чел.}$$

По формуле (2) выборочные начальные моменты равны:

$$a_1 = 4,385 \text{ млн чел.} - \text{совпадает с выборочным средним;}$$

Выборочные центральные моменты по формуле (3):

$$m_2 = 51,175 \text{ млн чел.}^2 - \text{смещённая выборочная дисперсия;}$$

$$m_3 = 666,021 \text{ млн чел.}^3$$

$$m_4 = 13924,662 \text{ млн чел.}^4$$

Смещённая выборочная дисперсия по формуле (4) равна:

$s^2 = 51,175 \text{ млн чел.}^2$ – средний квадрат отклонений числа международных туристов от среднего значения по региону.

Подставив значение формулы (4) в формулу (5), получим среднее квадратическое отклонение:

$s = 7,154 \text{ млн чел.}$ – типичное (среднее) отклонение числа туристов в отдельных странах от среднего значения по региону. То есть, в среднем количество туристов в отдельных странах отклоняется от среднего значения (4,385 млн чел.) примерно на 7,154 млн чел.

Рассчитанные оценки показывают, что среднее количество международных туристов по странам Азии и Тихого океана составляет 4,385 млн чел. за 2023 год. Однако это усреднённая характеристика, которая не отражает реальной картины. Так, тройка стран-лидеров (Таиланд, Малайзия и Индия) значительно превышают среднее значение, при этом большинство

стран имеют показатели ниже этого уровня. Поэтому среднее значение оказывается сильно завышенным. Это подтверждается положительным коэффициентом асимметрии ($A_s = \frac{m_3}{s^3} = \frac{666,021}{7,154^3} \approx 1,82$), который говорит о правосторонней асимметрии данных, а также эксцессом ($e = \frac{m_4}{s^4} - 3 = \frac{13924,662}{7,154^4} - 3 \approx 2,32$), показывающим островершинное распределение с тяжёлыми хвостами. Это вызвано тем, что большинство сконцентрированы в диапазоне малых значений приёма туристов, при этом есть несколько стран с очень большими показателями. Поэтому, следует рассматривать медианное значение при дальнейшем анализе данных.

Кроме того, средний квадрат отклонения в 51,175 млн чел.² свидетельствует и сильной вариации туристических потоков между странами региона и неоднородности данных. Это подтверждается большим значением коэффициента вариации ($CV = \frac{s}{\bar{x}} \times 100\% = \frac{7,154}{4,385} \times 100\% \approx 163\%$), то есть страны в регионе имеют большие различия в количестве прибывающих туристов.

Также были проведены расчёты дополнительных выборочных оценок.

Выборочная медиана:

$$med = \begin{cases} x_{(l+1)}, & n = 2l + 1 \\ \frac{x_{(l)} + x_{(l+1)}}{2}, & n = 2l \end{cases}; \quad (6)$$

Где:

n – объём выборки;

l – число для определения позиции медианы;

x_i – элемент вариационного ряда.

При $n = 34$ $l = 17$, тогда по формуле (6) $med = \frac{x_{17} + x_{18}}{2} = \frac{0,93 + 0,66}{2} \approx 0,80$ млн чел.

Значит, половина всех стран (17 из 34) принимают менее 0,80 млн международных туристов, другая половина – более 0,80 млн.

Выборочные квартили:

$$z_{1/4} = x_{(i)} \quad z_{3/4} = x_{(n-i+1)} \quad i = \begin{cases} [n/4] + 1, \frac{n}{4} - \text{дробное} \\ \frac{n}{4}, \frac{n}{4} - \text{целое} \end{cases}; \quad (7)$$

При $n = 34$ по формуле (7):

$$z_{1/4} = 0,09 \text{ млн чел.}$$

$$z_{3/4} = 4,90 \text{ млн чел.}$$

25% стран региона принимают менее 0,09 млн туристов. Это такие направления, как Микронезия (0,0 млн чел.), Маршалловы Острова (0,01 млн чел.), Кирибати (0,01 млн чел.) и другие. 75% стран региона принимают менее 4,90 млн туристов, и лишь 25% стран превышают этот порог, что указывает на концентрацию туристических потоков в ограниченном числе направлений.

Выборочное среднее абсолютное отклонение:

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - med|, \quad (8)$$

Где:

n – объём выборки;

x_i – элемент выборки;

med – выборочная медиана.

При $n = 34$ по формуле (8):

$$d = \frac{1}{34} \sum_{i=1}^n |x_i - 0,80| = 4,23 \text{ млн чел.}$$

Значение показывает, что количество туристов в отдельных странах отклоняется от медианного значения (0,80 млн чел.) примерно на 4,23 млн чел. Этот показатель, в отличие от среднеквадратичного отклонения,

устойчив к выбросам и лучше характеризует разброс данных при асимметричном распределении.

Полусумма выборочных квартилей:

$$t_q = \frac{1}{2}(z_{1/4} + z_{3/4}) \quad (9)$$

По формуле (9):

$$t_q = \frac{1}{2}(0,09 + 4,90) = 2,49 \text{ млн чел.}$$

Полусумма квартилей – это значение, находящееся в середине диапазона $[z_{1/4}; z_{3/4}]$. $t_q = 2,49$ млн чел. лежит между медианой (0,80 млн чел.) и средним значением (4,385 млн чел.), что подтверждает правостороннюю асимметрию распределения. Кроме того, полусумма квартилей устойчива к выбросам.

Полусумма экстремальных выборочных элементов:

$$t_R = \frac{1}{2}(x_{min} + x_{max}) \quad (10)$$

По формуле (10):

$$t_R = \frac{1}{2}(0,0 + 28,2) = 14,10 \text{ млн чел.}$$

Полусумма экстремальных выборочных элементов равна центру между наименьшим (Микронезия – 0,0 млн чел.) и наибольшим (Таиланд – 28,2 млн чел.) значениями выборки. Данный показатель очень чувствителен к выбросам. Так, $t_R = 14,10$ млн чел. значительно превышает среднее значение (4,385 млн чел.) и медиану (0,80 млн чел.), что подтверждает большое влияние выбросов на распределение.

Разность выборочных квартилей:

$$q = z_{3/4} - z_{1/4}, \quad (11)$$

По формуле (11):

$$q = 4,90 - 0,09 = 4,81 \text{ млн чел.}$$

Межквартильный размах показывает диапазон, в котором находятся центральные 50% стран от 0,09 до 4,90 млн туристов. Это устойчивая мера разброса, независящая от выбросов. Относительно большое значение $q = 4,81$ млн чел. говорит о высокой неоднородности данных.

Размах выборки:

$$R = x_{max} - x_{min}, \quad (12)$$

По формуле (12):

$$R = 28,2 - 0,0 = 28,2 \text{ млн чел.}$$

Размах выборки демонстрирует огромный разрыв между страной-лидером (Таиланд – 28,2 млн чел.) и страной с наименьшим турпотоком (Микронезия – 0,0 млн чел.). Это говорит о неравномерности распределения международного туризма в регионе Азии и Тихого океана.

Вывод: Статистический анализ выборочных оценок показывает, что распределение международных туристских прибытий по странам региона Азия и Тихий океан в 2023 году характеризуется крайней неоднородностью, выраженной правосторонней асимметрией и островершинной формой. Среднее значение (4,385 млн. чел.) не отражает типичный уровень турпотока из-за доминирования нескольких стран-лидеров, которые непропорционально влияют на статистику региона. Ввиду этого, медиана (0,80 млн чел.) является более подходящей мерой центральной тенденции. Типичная страна региона принимает около 0,80 млн туристов. Разброс данных вокруг медианы характеризуется значением $d = 4,23$ млн чел., что указывает на значительную неоднородность даже при использовании устойчивой меры. Расчёт дополнительных числовых показателей подтвердил

неоднородное распределение туристических прибытий с правосторонней асимметрией и тяжёлыми хвостами.

1.3 Оценка плотности распределения

Для оценки плотности и характера распределения построим гистограмму плотности распределения – фигуру, образованную прямоугольниками с основанием Δ_i и высотами $n_i/(nh)$ (плотность вероятности), где:

n_i – частота попадания элементов выборки в интервал Δ_i ;

n – объём выборки;

h - длина интервала.

Исходные данные:

Объём выборки: $n = 34$

Минимальное значение: $x_{mi} = 0$ млн чел.

Максимальное значение: $x_{max} = 28,2$ млн чел.

Определение числа интервалов:

По формуле Старджесса:

$$k = 1 + 3,3 \lg n = 1 + 3,3 \lg 34 \approx 1 + 3,3 \times 1,53 \approx 6$$

Длина интервала:

$$h = \frac{x_{max} - x_{min}}{k} = \frac{28,2 - 0,0}{6} = 4,7 \text{ млн чел.}$$

Ниже представлена гистограмма плотности распределения, построенная в Google Colab с помощью Python (рис. 2).




Рисунок 2 – Гистограмма плотности распределения

Описание данных гистограммы:

Гистограмма демонстрирует выраженную концентрацию стран в области низких значений туристического потока. Первый интервал $[0; 4,7)$ млн чел. содержит 25 из 34 стран (73,5% выборки), что соответствует плотности вероятности 0,156. Это означает, что более половины стран региона принимают менее 4,7 млн международных туристов в год (2023).

Распределение характеризуется сильной правосторонней асимметрией: после резкого падения плотности во втором интервале $[4,7; 9,4)$ до значения 0,012, остальные интервалы имеют низкие и приблизительно равные плотности. Такая форма указывает на наличие «длинного правого хвоста», образованного странами с высокими показателями турпотока, что подтверждается ранее вычисленным коэффициентом асимметрии ($A_s \approx 1,82$).

Высокий первый столбец гистограммы при низких значениях в остальных интервалах свидетельствует об островершинной форме распределения с высокой концентрацией значений в области минимальных

показателей, что также согласуется с эксцессом ($e \approx 2,32$).

Страны с максимальными показателями (Таиланд – 28,2 млн чел., Малайзия – 20,1 млн чел., Индия – 18,9 млн чел.) попадают в последние интервалы $[18,8; 23,5)$ и $[23,5; 28,2]$, формируя «правый хвост» распределения. Эти значения существенно отклоняются от основной массы данных.

При этом наложение кривой нормального распределения на гистограмму показывает существенное расхождение между эмпирическим (по фактическим выборочным данным) и теоретическим распределениями:

- Нормальная кривая имеет максимум в точке среднего значения (4,385 млн чел.) и симметрична относительно неё;
- Эмпирическое распределение имеет максимум в области $[0; 4,7)$ и резко асимметрична;
- Плотность нормального распределения в области малого значения (около 0,045) значительно ниже эмпирической плотности (0,156).

На основе анализа гистограммы выдвигается нулевая гипотеза H_0 :

Исследуемая величина (количество международных туристов) имеет нормальное распределение, с правосторонней асимметрией.

Также выдвигается гипотеза H_1 :

Исследуемая величина имеет ненормальное распределение.

Для проверки используется критерий хи-квадрат Пирсона:

$$\chi^2_{\text{в}} = \sum_{i=1}^k \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i}, \quad (13)$$

Где:

n_i – наблюдаемая частота попадания в интервал Δ_i ;

$n\hat{p}_i$ – теоретическая частота, рассчитанная исходя из предполагаемого распределения;

$\hat{p}_i = P(X \in \Delta_i)$ – вероятность попадания в интервал.

Теорема Фишера: статистика χ^2 асимптотически распределена по

закону χ^2 с числом степеней свободы:

$$r = k - 1 - l,$$

Где:

l – число параметров, оценённых по выборке.

Проверка:

1. Выбор уровня значимости: $\alpha = 0,05$
2. Расчёт теоретических вероятностей для нормального распределения:

$$\hat{p}_i = P(a_{i-1} \leq X < a_i) = \Phi\left(\frac{a_i - \mu}{\sigma}\right) - \Phi\left(\frac{a_{i-1} - \mu}{\sigma}\right), \quad (14)$$

Где:

$\Phi(x)$ – функция стандартного нормального распределения;

$\mu = \bar{x} = 4,385$ млн чел. – оценённое математическое ожидание;

$\sigma = s = 7,154$ млн чел. – оценённое среднеквадратичное отклонение;

a_{i-1}, a_i – границы i -го интервала.

Функция стандартного нормального отклонения при стандартной нормальной величине $Z \sim N(0, 1)$:

$$\Phi(x) = P(Z \leq x), \quad (15)$$

Но распределение не нормальное, поэтому:

$$Z = \frac{X - \mu}{\sigma}, \quad (16)$$

Тогда по формуле (16):

$$P(a_{i-1} \leq X < a_i) = P\left(\frac{a_{i-1} - \mu}{\sigma} \leq Z < \frac{a_i - \mu}{\sigma}\right), \quad (17)$$

По свойствам вероятностей:

$$\begin{aligned}
 P\left(\frac{a_{i-1} - \mu}{\sigma} \leq Z < \frac{a_i - \mu}{\sigma}\right) &= \\
 = P\left(Z < \frac{a_i - \mu}{\sigma}\right) - P\left(Z < \frac{a_{i-1} - \mu}{\sigma}\right), & \quad (18)
 \end{aligned}$$

По формуле (18):

$$P\left(Z < \frac{a_i - \mu}{\sigma}\right) - P\left(Z < \frac{a_{i-1} - \mu}{\sigma}\right) = \Phi\left(\frac{a_i - \mu}{\sigma}\right) - \Phi\left(\frac{a_{i-1} - \mu}{\sigma}\right)$$

Значения вероятностей по интервалам представлены в таблице 2.

Таблица 2 – Теоретические вероятности

Интервал	n_i	$\hat{p}_i$	$n\hat{p}_i$	$\frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i}$
[0; 4,7)	25	0,248	8,419	32,657
[4,7; 9,4)	2	0,241	8,187	4,676
[9,4; 14,1)	2	0,154	5,250	2,012
[14,1; 18,8)	2	0,065	2,219	0,022
[18,8; 23,5)	2	0,018	0,618	3,089
[23,5; 28,2]	1	0,003	0,113	6,936

3. Вычисление $\chi^2_{\text{в}}$ с помощью формулы (13):

$$\chi^2_{\text{в}} = 32,657 + 4,676 + 2,012 + 0,022 + 3,089 + 6,936 = 49,391$$

Число степеней свободы:

$$r = k - 1 - l = 6 - 1 - 2 = 3,$$

Где $l = 2$ (число оценённых параметров μ и σ).

4. Вычисление квантиля распределения $\chi^2_{1-\alpha}(r)$:

$$\chi^2_{0,95}(3) = 7,815$$

5. Сравнение:

$49,391 > 7,815$, соответственно $\chi^2_{\text{в}} > \chi^2_{0,95}(3)$. Значит, гипотеза о

нормальном распределении отвергается, данные не согласуются с нормальным распределением. Для дальнейшего описательного анализа целесообразно использовать робастные характеристики: медиану как меру центра и среднее абсолютное отклонение от медианы как меру разброса.

Поскольку гипотеза о нормальном распределении не подтвердилась, проверим другую: данные подчиняются экспоненциальному распределению.

Для этого построим ядерную оценку плотности (KDE) с наложением теоретической экспоненциальной кривой с параметром $\hat{\lambda} = \frac{1}{\bar{x}} \approx 0,228$ (рис. 3), а также график проверки соответствия выборки теоретическому распределению Q-Q plot (рис. 4).




Рисунок 3 – Экспоненциальное распределение




Рисунок 4 – Q-Q plot данных и экспоненциального распределения

Визуальный анализ KDE показал, что эмпирическая плотность имеет выраженный пик в области малых значений (0–1 млн чел.), тогда как экспоненциальная кривая начинается с максимума при $x = 0$ и монотонно убывает. Правый хвост эмпирического распределения «тяжелее» экспоненциального: наблюдается избыток экстремальных значений (страны-лидеры). Данные показатели нехарактерны для экспоненциального характера распределения.

На Q-Q plot точки систематически отклоняются от прямой в области больших квантилей, что подтверждает несоответствие экспоненциальной модели. Точки в правой части графика отклоняются вверх от прямой, что говорит о «тяжёлом» правом хвосте и наличии выбросов.

Кроме того, был применён критерий Колмогорова-Смирнова:

При $\alpha = 0,05$:

$$D_{\text{крит}} = \frac{c(\alpha)}{\sqrt{n}} = \frac{1,36}{\sqrt{34}} \approx 0,233$$

$$D = 0,384$$

$$P_value = 0,0001$$

Поскольку $0,384 > 0,233$ и $0,0001 < 0,05$, гипотеза о том, что распределение имеет экспоненциальный характер отвергается. Распределение данных выборки не является нормальным и экспоненциальным.

Вычисления проводились с помощью языка Python.

Вывод: Распределение международных туристских прибытий по странам региона Азия и Тихий океан в 2023 году не является нормальным ($\chi^2_{\text{в}} > \chi^2_{0,95}(3)$). Дополнительная проверка гипотезы об экспоненциальном распределении также не подтвердилась. Визуальный анализ KDE показал расхождение эмпирической и теоретической плотностей, на Q-Q plot точки систематически отклоняются от прямой в области больших квантилей, критерий Колмогорова-Смирнова показал $D = 0,384 > 0,233$, $p\text{-value} = 0,0001 < 0,05$. Таким образом, данные имеют сложную асимметричную структуру с правосторонней скошенностью и «тяжелым правым хвостом». Полученные результаты отражают существенную поляризацию региона Азия и Тихий океан по уровню развития международного туризма. Большинство стран региона имеют скромные показатели туристической активности, в то время как несколько стран-лидеров концентрируют основную долю международного турпотока. Это объясняет целесообразность использования робастных характеристик (медианы и среднего абсолютного отклонения) для описания центральной тенденции и разброса данных.

1.4 Интервальные оценки числовых характеристик данных

Для построения доверительных интервалов при большом объёме выборки $n = 34$ необходимо использовать формулы произвольной генеральной совокупности.

Доверительный интервал для математического ожидания:

$$P\left(\bar{x} - \frac{\sigma u_{1-\frac{\alpha}{2}}}{\sqrt{n}} < a < \bar{x} + \frac{\sigma u_{1-\frac{\alpha}{2}}}{\sqrt{n}}\right) = 1 - \alpha, \quad (19)$$

Где:

$\sigma = s = 7,154$ млн чел. – среднеквадратическое отклонение генеральной совокупности;

$u_{1-\frac{\alpha}{2}}$ – квантиль стандартного нормального распределения;

$\bar{x} = 4,385$ млн чел. – выборочное среднее;

$\alpha = 0,05$ – уровень значимости;

$n = 34$ – объём выборки.

Квантиль стандартного нормального распределения:

$$u_{1-\frac{\alpha}{2}} = u_{0,975} = 1,96$$

Расчёт границ доверительного интервала:

Погрешность оценки:

$$\Delta = \frac{\sigma u_{1-\frac{\alpha}{2}}}{\sqrt{n}} = \frac{7,154 \cdot 1,96}{\sqrt{34}} = 2,405$$

Нижняя граница:

$$a_{\text{ниж}} = \bar{x} - \Delta = 4,385 - 2,405 = 1,98 \text{ млн чел.}$$

Верхняя граница:

$$a_{\text{верх}} = \bar{x} + \Delta = 4,385 + 2,405 = 6,79 \text{ млн чел.}$$

Доверительный интервал по формуле (19):

$$(1,98; 6,79) \text{ млн чел.}$$

Вывод: С доверительной вероятностью 95% можно утверждать, что истинное среднее количество международных туристов по всем странам региона Азия и Тихий океан находится в интервале от 1,98 до 6,79 млн. человек. При этом:

$$\text{Ширина интервала: } 6,79 - 1,98 = 4,81 \text{ млн чел.;}$$

$$\text{Относительная погрешность: } (4,81/2)/4,385 \times 100\% \approx 54,9\%.$$

Относительно большая ширина доверительного интервала свидетельствует о низкой точности оценки среднего значения из-за высокой вариации данных и сильной асимметрии распределения.

Доверительный интервал для среднеквадратичного отклонения:

$$P\left(s\left(1 - \frac{1}{2}u_{1-\frac{\alpha}{2}}\sqrt{\frac{e+2}{n}}\right) < \sigma < s\left(1 + \frac{1}{2}u_{1-\frac{\alpha}{2}}\sqrt{\frac{e+2}{n}}\right)\right) = 1 - \alpha \quad (20)$$

Где:

$s = 7,154$ млн чел. – среднеквадратичное отклонение;

σ – истинное среднеквадратичное отклонение генеральной совокупности;

$e = 2,317$ – коэффициент эксцесса;

$u_{1-\frac{\alpha}{2}}$ – квантиль стандартного нормального распределения;

$\alpha = 0,05$ – уровень значимости;

$n = 34$ – объём выборки.

Расчёт границ доверительного интервала:

$$\frac{1}{2}u_{1-\frac{\alpha}{2}}\sqrt{\frac{e+2}{n}} = \frac{1}{2} \cdot 1,96 \cdot \sqrt{\frac{2,317+2}{34}} = 0,349$$

Нижняя граница:

$$\sigma_{\text{ниж}} = s \cdot \left(1 - \frac{1}{2}u_{1-\frac{\alpha}{2}}\sqrt{\frac{e+2}{n}}\right) = 7,154 \cdot (1 - 0,349) = 4,656 \text{ млн чел.}$$

Верхняя граница:

$$\sigma_{\text{верх}} = s \cdot \left(1 + \frac{1}{2}u_{1-\frac{\alpha}{2}}\sqrt{\frac{e+2}{n}}\right) = 7,154 \cdot (1 + 0,349) = 9,652 \text{ млн чел}$$

Доверительный интервал по формуле (20):

(4,656; 9,652) млн чел.

Вывод: С доверительной вероятностью 95% можно утверждать, что истинное среднеквадратичное отклонение количества международных

туристов в генеральной совокупности стран региона находится в интервале от 4,656 до 9,652 млн человек. При этом:

Истинный разброс данных вокруг среднего значения лежит в пределах от 4,656 до 9,652 млн чел.;

Ширина интервала: $9,652 - 4,656 = 4,996$ млн. чел.;

Относительная погрешность: $(4,996/2)/7,154 \times 100\% \approx 34,9\%$.

Доверительный интервал для среднеквадратичного отклонения меньше, чем для матожидания, что указывает на более точную оценку параметра разброса.

1.5 Выводы

В рамках данной практической работы было проведено статистическое исследование международных туристических прибытий по 34 странам Азии и Тихого океана за 2023 год. В ходе исследования были сделаны выборочные ($\bar{x} = 4,385$ млн чел., $s = 7,154$ млн чел.) и робастные оценки ($\text{med} = 0,80$ млн чел., $d = 4,23$ млн чел.).

Анализ гистограммы плотности показал правостороннюю асимметрию распределения с «длинным правым хвостом», что говорит о малой концентрации стран в области высоких показателей турпотока.

Проверка гипотезы о нормальном распределении хи-квадрат Пирсона опровергла нулевую гипотезу H_0 о нормальном распределении ($\chi^2_{\text{в}} > \chi^2_{0,95}(3)$). Проверка экспоненциального характера распределения также не подтвердилась. Соответственно данные имеют правостороннюю асимметрию с концентрацией большинства стран в области малых значений.

Значительное расхождение между средним (4,385 млн чел.) и медианой (0,80 млн чел.) свидетельствует о сильном влиянии выбросов (стран-лидеров). Поэтому медиана является более подходящей характеристикой «типичной» страны региона. Среднее абсолютное отклонение от медианы ($d = 4,23$ млн чел.) подтверждает высокую неоднородность данных даже при

использовании робастной меры разброса.

Широкие доверительные интервалы (для математического ожидания: (1,98; 6,79) млн чел., для среднеквадратичного отклонения: (4,656; 9,652) млн чел.) указывают на высокую вариацию данных.

2 Дополнительная часть

2.1 Оценка дополнительных данных

Чтобы провести оценку дополнительных данных, можно исключить из выборки страны с низким прибытием международных туристов. Тогда будет возможность сравнить ранее рассчитанные показатели с новыми.

Из выборки данных были исключены 18 стран с турпотоком менее 1 млн чел. в год.

Среднее значение при новой выборке увеличилось с 4,385 млн чел. до $\bar{x} = 9,1$ млн чел., медиана – с 0,80 млн чел. до 5,5 млн чел. Это означает, что правосторонняя асимметрия сохраняется ($9,1 \text{ млн чел.} > 5,5 \text{ млн чел.}$).

Среднеквадратическое отклонение стало $s = 8,166$ млн чел. (предыдущее: $s = 7,154$ млн чел.), поскольку в выборке по-прежнему остались страны-лидеры.

Коэффициент асимметрии уменьшился с 1,82 до 0,83 – распределение стало более симметричным, хотя правосторонняя асимметрия остаётся. Эксцесс также снизился до -0,45 (было 2,32), то есть распределение стало более плоское. Соответственно туристические потоки распределены более равномерно между странами.

Коэффициент вариации без нетуристических стран – 90% (был 163%). Это говорит о том, что данные стали более однородными, хотя неоднородность всё ещё сохраняется.

Для наглядности построим гистограмму плотности распределения (рис. 5).




Рисунок 5 – Гистограмма распределения плотности без нетуристических стран

Вывод: после исключения из выборки 18 стран с турпотокотом менее 1 млн человек произошли существенные изменения в статистических характеристиках распределения. Среднее значение увеличилось с 4,385 до 9,1 млн чел., а медиана выросла с 0,795 до 5,500 млн чел., причём медиана изменилась более значительно (почти в 7 раз), что свидетельствует о том, что исключённые страны были сконцентрированы в нижней части распределения и сильно занижали типичное значение турпотока. Коэффициент асимметрии уменьшился с 1,819 до 0,828, что указывает на приближение распределения к симметричному, хотя правосторонняя асимметрия всё ещё сохраняется. Эксцесс изменился с положительного значения 2,317 на отрицательное в (-0,449), что говорит о переходе от островершинного распределения с тяжёлыми хвостами к более плосковершинной форме. Коэффициент вариации снизился с 163% до 90%, что свидетельствует о повышении однородности выборки после удаления малых стран, хотя разброс данных остаётся значительным. Среднеквадратичное отклонение незначительно выросло с 7,154 до 8,166 млн чел., что объясняется сохранением в выборке стран-лидеров с высокими показателями. В целом, после исключения малых

стран распределение стало более симметричным и однородным, приблизившись по своим характеристикам к нормальному распределению.

2.2 Построение Boxplot

Для визуализации прибытий международных туристов по 34 странам Азии и Тихого Океана построен boxplot, показывающий статистические характеристики выборки (рис. 6). Он объединён с скрипичной диаграммой, передающей плотность распределения.




Рисунок 6 – Boxplot с скрипичной диаграммой

При анализе boxplot видно, что ящик (IQR) охватывает диапазон 0,09 – 4,9, млн чел, поскольку показатели половины стран лежат в этих значениях. Медиана (0,80 млн чел.) смещена влево, что указывает на правостороннюю асимметрию распределения. Левый ус достигает значений около 0,0 млн чел. (Микронезия – 0,0 млн чел, Кирибати – 0,01 млн чел), правый ус приближен к отметке 12 млн чел. (Индонезия – 11,4 млн чел, Сингапур – 10,8 млн чел).

Скрипичная диаграмма также демонстрирует правостороннюю асимметрию распределения данных. Широкая часть слева (0 – 1 млн чел) указывает на высокую концентрацию стран с небольшими показателями туристических прибытий, а узкий вытянутый хвост справа свидетельствует о

наличии стран-лидеров с большими значениями.

На графике видны 5 выбросов, расположенные справа за пределами правого уса (14-28 млн чел.). Это, соответственно, 5 стран-лидеров по прибытиям туристов (Макао – 14,2 млн чел, Гонконг – 17,2 млн чел, Индия – 18,9 млн чел, Малайзия – 20,1 млн чел, Таиланд – 28,2 млн чел). Таким образом, видно, что большую часть туристов принимают лишь несколько стран, при этом большинство стран региона имеют гораздо меньшие показатели.

Вывод: в результате построения boxplot с скрипичной диаграммой подтверждается правосторонняя асимметрия распределения. Большинство стран сконцентрировано в диапазоне 0 – 1 млн туристов, наблюдаются 5 выбросов стран-лидеров, формирующих длинный правый хвост распределения. Межквартильный размах ($IQR = 4,81$ млн чел) относительно велик по сравнению с медианой (0,80 млн чел), что говорит о неоднородности данных.

2.3 Расчёт дополнительных числовых показателей

Были проведены расчёты оценок без учета 18 стран.

Выборочная медиана:

При $n = 16$ $l = 8$, тогда по формуле (6) $med = \frac{x_8 + x_9}{2} = \frac{5,5 + 5,5}{2} = 5,5$ млн чел.

Значит, половина стран (8 из 16) принимают менее 5,5 млн международных туристов, другая половина – более 5,5 млн.

Выборочные квартили:

При $n = 16$ по формуле (7):

$$z_{1/4} = 2,12 \text{ млн чел.}$$

$$z_{3/4} = 14,95 \text{ млн чел.}$$

25% стран региона принимают менее 2,12 млн туристов. Это такие

направления, как Непал (1 млн чел.), Мьянма (1,3 млн чел.), Шри-Ланка (1,5 млн чел.) и другие. 75% стран региона принимают менее 14,95 млн туристов, и лишь 25% стран превышают этот порог, что указывает на концентрацию туристических потоков в ограниченном числе направлений.

Выборочное среднее абсолютное отклонение:

При $n = 16$ по формуле (8):

$$d = \frac{1}{16} \sum_{i=1}^n |x_i - 5,5| = 6,69 \text{ млн чел.}$$

Значение показывает, что в среднем страны отклоняются от медианы на 6,69 млн туристов. Оно относительно невелико по сравнению с медианой (5,5 млн чел.), это говорит о том, что данные выборки стали более однородными.

Полусумма выборочных квартилей:

По формуле (9):

$$t_q = \frac{1}{2}(2,12 + 14,95) = 8,54 \text{ млн чел.}$$

Полусумма квартилей – это значение, находящееся в середине диапазона $[z_{1/4}; z_{3/4}]$. $t_q = 8,54$ млн чел. лежит между медианой (5,5 млн чел.) и средним значением (9,1 млн чел.), что подтверждает правостороннюю асимметрию распределения. Кроме того, полусумма квартилей устойчива к выбросам.

Полусумма экстремальных выборочных элементов:

По формуле (10):

$$t_R = \frac{1}{2}(1,0 + 28,2) = 14,6 \text{ млн чел.}$$

Полусумма экстремальных выборочных элементов равна центру между наименьшим (Непал – 1 млн чел.) и наибольшим (Таиланд – 28,2 млн чел.) значениями выборки. Данный показатель очень чувствителен к выбросам.

Так, $t_R = 14,6$ млн чел. значительно превышает среднее значение (9,1 млн чел.) и медиану (5,5 млн чел.), что подтверждает большое влияние выбросов на распределение.

Разность выборочных квартилей:

По формуле (11):

$$q = 14,95 - 2,12 = 12,83 \text{ млн чел.}$$

Межквартильный размах показывает диапазон, в котором находятся центральные 50% стран от 2,12 до 14,95 млн туристов. Это устойчивая мера разброса, независимая от выбросов.

Размах выборки:

По формуле (12):

$$R = 28,2 - 1,0 = 27,2 \text{ млн чел.}$$

Размах выборки демонстрирует огромный разрыв между страной-лидером (Таиланд – 28,2 млн чел.) и страной с наименьшим турпоток (Непал – 1,0 млн чел.). Это говорит о неравномерности распределения международного туризма в регионе Азии и Тихого океана.

Вывод: расчёт числовых показателей без учёта нетуристических стран выявил более однородное распределение туристических прибытий, однако правосторонняя асимметрия сохранилась.

2.4 Выводы

Было проведено статистическое исследование распределения международных туристических прибытий по 34 странам региона Азия и Тихий океан за 2023 год. Выявлена особенность, характерная для данных с выраженной структурной неоднородностью. Анализ показал, что регион представляет собой крайне поляризованную систему, где несколько стран-лидеров (Таиланд, Малайзия, Индия, Гонконг и Макао) концентрируют основную долю международного турпотока, в то время как подавляющее большинство государств (25 из 34, что составляет 73,5%) принимают менее

4,7 млн. туристов ежегодно. Среднее значение в 4,385 млн. чел. оказалось в 5,5 раза выше медианы (0,80 млн. чел.), что наглядно демонстрирует искажающее влияние экстремальных значений. Поэтому медиана является более адекватной характеристикой "типичной" страны региона, так как не искажается значениями стран-лидеров.

Проверка гипотезы о нормальности распределения с помощью критерия хи-квадрат Пирсона дала однозначный результат: наблюдаемое значение статистики ($\chi^2_{\text{в}} = 49,391$) превысило квантиль распределения хи-квадрат ($\chi^2_{1-\alpha}(r) = 7,815$), что привело к отвержению нулевой гипотезы на уровне значимости 0,05.

Гипотеза об экспоненциальном характере распределения также не подтвердилась: эмпирическая плотность и точки на графиках расходятся с экспоненциально кривой и прямой, $D = 0,384 > 0,233$, $p\text{-value} = 0,0001 < 0,05$.

Полученные коэффициенты асимметрии ($A_s = 1,82$) и эксцесса ($e = 2,32$) количественно подтвердили визуальную картину: распределение характеризуется сильным правосторонним перекосом с островершинной формой и тяжёлыми хвостами.

Коэффициент вариации, достигший 163%, свидетельствует о крайней неоднородности данных, где разброс данных вокруг медианы ($d = 4,23$ млн чел.) подтверждает высокую неоднородность туристических потоков. Построение доверительных интервалов для математического ожидания (1,96; 6,79 млн. чел.) и среднеквадратичного отклонения (4,656; 9,652 млн. чел.) продемонстрировало существенную неопределённость оценок, обусловленную как неоднородностью выборки, так и высокой вариативностью данных. Расчёт дополнительных характеристик (межквартильный размах $q = 4,81$ млн. чел., среднее абсолютное отклонение) подтвердил целесообразность использования устойчивых к выбросам статистик для описания центральной тенденции и разброса в данной совокупности.

Визуализация данных через boxplot и скрипичную диаграмму наглядно представила статистические выбросы, соответствующий странам с показателями выше 12,12 млн. чел., что составляет 14,7% от общего числа наблюдений. Это Таиланд (28,2 млн чел.), Малайзия (20,1 млн чел.), Индия (18,9 млн чел.), Гонконг (17,2 млн чел.) и Макао (14,2 млн чел.). Исключение 18 стран из выборки привело к повышению среднего значения, среднеквадратичного отклонения и медианы, а также к понижению коэффициента асимметрии, эксцесса и коэффициента вариации, что свидетельствует о более однородных данных, плоском распределении, но с сохранением асимметрии. Это также подтверждается дополнительными числовыми показателями, вычисленные на основе усечённой выборки.

ЗАКЛЮЧЕНИЕ

В процессе выполнения данной практической работы были систематизированы и отработаны ключевые навыки в области статистики: от первичного описания выборки до проверки гипотез с помощью хи-квадрат и построения доверительных интервалов. Были произведены расчёты, характеризующие асимметрию распределения данных.

Техническая реализация анализа осуществлялась с применением языка программирования Python и специализированных библиотек (pandas для обработки табличных данных, numpy для численных расчётов, matplotlib для визуализации, scipy для статистических тестов, google.colab для загрузки файла). Такой подход позволил не только автоматизировать вычисления, но и создать наглядные графические представления распределения, что существенно облегчило интерпретацию результатов.

Установлено, что выбросы значительно искажают статистические данные. Это подтверждает необходимость использования оценок, независимых от них.

Также было сформировано представление о статистическом анализе, как о многоуровневом процессе.

ПРИЛОЖЕНИЕ

1. Программы создания графиков и расчётов. URL: <https://github.com/serg-358/Statistic-1>